



TEHNIČKA DOKUMENTACIJA SUSTAVA

MarathonOCR

Automatsko prepoznavanje startnih brojeva i pretraga fotografija s utrke — pregled sustava, značajke, arhitektura, tehnološki stog, kapacitet i operativni priručnik.

Sadržaj

1	Pregled sustava	2		
1.1	Problem koji rješava	2		
1.2	Rješenje u jednoj rečenici	2		
1.3	Tko koristi sustav	2		
1.4	Komponente na prvi pogled	2		
2	Značajke	3		
2.1	Za trkače (javna stranica)	3		
2.2	Za organizatora i operatera	4		
2.3	Privatnost ugrađena u dizajn	4		
3	Kako sustav radi	5		
3.1	Tijek podataka	5		
3.2	Zašto u tri koraka: detekcija, izrez, čitanje	5		
3.3	Kako trkač pronalazi fotografije	5		
4	Komponente sustava	6		
4.1	OCR cjevovod (Python)	6		
4.2	Aplikacija za pregled	6		
4.3	Uvozne skripte	7		
4.4	Baza podataka (Supabase / PostgreSQL)	7		
4.5	Javna web stranica	7		
5	Tehnološki stog	11		
5.1	Arhitektonske odluke	12		
6	Kapacitet: koliko korisnika sustav podnosi	13		
6.1	Gdje je usko grlo	13		
6.2	Mjerenje pretrage	13		
6.3	Prijenos fotografija	14		
6.4	Kako povećati kapacitet	14		
6.5	Brzina obrade fotografija	15		
7	Točnost prepoznavanja	16		
7.1	Čitanje broja po veličini	16		
7.2	Kaskada: EasyOCR + AI rezerva	16		
7.3	Što to znači u praksi	16		
8	Sigurnost i privatnost	4		
8.1	Zaštita podataka u bazi	17		
8.2	Zaštita web stranice	17		
8.3	GDPR i pravna dokumentacija	17		
9	Operativni priručnik: jedan događaj	18		
9.1	Jednokratna priprema	18		
9.2	Na dan utrke	18		
9.3	Objava web stranice	19		
9.4	Konfiguracija	19		
10	Troškovi rada	20		
11	Ograničenja i plan razvoja	21		
12	Pojmovnik	22		

1 Pregled sustava

MarathonOCR automatski pronalazi startne brojeve na fotografijama s utrke i svakom trkaču u nekoliko sekundi prikazuje sve fotografije na kojima se nalazi — bez ručnog označavanja, bez prepoznavanja lica.

1.1 Problem koji rješava

Na velikoj utrci fotografi snime desetke tisuća fotografija, a trkač želi vidjeti *svoje*, ne prelistavati cijelu galeriju. Ručno označavanje 20.000 fotografija traje danima, a običan OCR ne radi jer je startni broj na fotografiji premalen (medijan u testnom skupu: 19 piksela visine).

1.2 Rješenje u jednoj rečenici

Računalo s grafičkom karticom obradi sve fotografije događaja (pronađe startne brojeve i pročita ih), operater po potrebi pregleda i ispravi rezultate, a zatim se sve objavljuje na brzoj web stranici na kojoj trkač upiše svoj startni broj i odmah dobije svoju galeriju.

~10 min

prepoznavanje brojeva za događaj
od 20.000 fotografija (RTX 5070)

98,5 %

točnost čitanja startnog broja uz
toleranciju jedne znamenke (kaskadni
način)

< 1 s

od upisa startnog broja do prikaza
galerije

1.3 Tko koristi sustav

ULOGA	ŠTO RADI U SUSTAVU
Trkač	Na web stranici upisuje startni broj, pregledava svoje fotografije po točkama na stazi, otvara ih u punoj veličini i preuzima.
Organizator utrke	Dostavlja popis trkača i rezultate (CSV od tvrtke za mjerenje vremena), objavljuje događaj i nudi trkačima uslugu pod vlastitim imenom i vizualnim identitetom.
Fotografi	Predaju mapu fotografija; po želji označavaju točku na stazi prefiksom imena datoteke (npr. <code>finish_0412.jpg</code>). Ime fotografa prikazuje se uz svaku fotografiju.
Operater (tehnička osoba)	Pokreće obradu na računalu s GPU-om, pregledava rezultate u aplikaciji za pregled, pokreće uvoz podataka i objavu.

1.4 Komponente na prvi pogled

① OCR cjevovod

Python biblioteka koja na fotografiji pronalazi startne brojeve (YOLO detektor) i čita ih (EasyOCR, s opcionalnim AI modelom kao rezervom).

② Aplikacija za pregled

Lokalna web aplikacija (Streamlit) u kojoj operater prolazi kroz fotografije, briše pogrešne i dodaje propuštene brojeve te izvozi CSV.

③ Uvozne skripte

Node.js skripte koje u bazu unose rezultate utrke, očitane brojeve i same fotografije (uz smanjivanje i opcionalni vođeni žig).

④ Javna web stranica

Next.js aplikacija izvezena kao statične datoteke, poslužena s Cloudflareove globalne mreže; podatke čita iz Supabase (PostgreSQL) baze.

2 Značajke

Popis mogućnosti sustava, grupiran prema tome kome koriste.

2.1 Za trkače (javna stranica)

ZNAČAJKA	OPIS
Pretraga po startnom broju	Jedno polje, dizajnirano kao startni broj utrke. Nije potrebna registracija ni korisnički račun.
Profil trkača	Ime, kategorija, klub, ciljno vrijeme, tempo (min/km) i plasman — preuzeto iz službenih rezultata.
Animirana staza	Traka od starta do cilja s oznakama (10K, polovica, 30K, cilj) i ciljnim vremenom trkača.
Galerija po točkama staze	Fotografije poredane po kilometru staze, a zatim po vremenu snimanja; svaka nosi oznaku točke i sat snimanja.
Tolerantno podudaranje	Ako je broj na fotografiji djelomično nečitljiv (npr. 1514 očitao kao 514), fotografija se ipak prikazuje, ali s oznakom VJEROJATNO . Točna i „vjerojatna“ podudaranja nikad se ne miješaju bez oznake.
Preglednik fotografija	Prikaz preko cijelog zaslona, navigacija tipkovnicom (← → Esc), ime fotografa, dimenzije originala, preuzimanje.
Dvojezičnost	Hrvatski (zadano) i engleski, s ispravnim hrvatskim množinama („1 fotografija“, „3 fotografije“, „11 fotografija“) i lokalnim formatom brojeva.
Prilagođeno mobitelima	Cijelo sučelje radi na mobitelu — gdje ga većina trkača i otvara, odmah nakon utrke.
Brojači na naslovnici	Broj finishera, godina prvog izdanja, duljina staze i rekord staze, izračunati iz baze.

2.2 Za organizatora i operatera

ZNAČAJKA	OPIS
Automatsko prepoznavanje	Detekcija i čitanje startnih brojeva na svim fotografijama događaja, u serijskoj obradi na jednom računalu.
Ljudska kontrola kvalitete	Aplikacija za pregled: fotografija s označenim brojevima, brisanje i dodavanje brojeva jednim klikom, automatsko spremanje napretka, izvoz CSV-a.
Uvoz rezultata bilo kojeg mjeraca vremena	Stupci se prepoznaju automatski (hrvatski i engleski nazivi: <code>startni broj</code> , <code>bib</code> , <code>StartNo</code> , <code>rezultat</code> ...), uz ručno mapiranje za neobične izvoze i „probni prolaz“ (<code>--dry-run</code>) koji ništa ne zapisuje.
Točke na stazi	Iz prefiksa imena datoteke, parametra po mapi ili iz zasebnog CSV-a s metapodacima (točka, kilometar, fotograf, vrijeme snimanja).
Priprema fotografija	Automatsko smanjivanje na web veličinu (zadano 1600 px), opcionalni vodeni žig; originali se čuvaju u zasebnom privatnom spremištu.
Više utrka u jednom događaju	Maraton, polumaraton, utrka na 10 km — svaka sa svojom duljinom i tempom.
Objava jednim prekidačem	Ništa nije javno vidljivo dok se događaj ne označi kao objavljen.
Demo način	Bez ikakve konfiguracije stranica radi na ugrađenim primjerima — korisno za prezentacije i testiranje.


2.3 Privatnost ugrađena u dizajn

- **Nema prepoznavanja lica** ni biometrijskih podataka — fotografija se povezuje s trkačem isključivo preko otisnutog startnog broja.
- Osobni podaci trkača nisu izravno čitljivi iz preglednika; do njih se dolazi samo kroz jednu kontroliranu funkciju u bazi (vidi poglavlje 8).
- Nema kolačića za analitiku ni oglašavanje; preglednik pamti samo odabrani jezik.
- Pripremljeni nacrti pravnih dokumenata: politika privatnosti, uvjeti korištenja, politika kolačića, DPIA predložak i postupak za zahtjeve ispitanika / uklanjanje fotografija.

3 Kako sustav radi

Sustav ima dvije polovice: **obradu**, koja se jednom po događaju pokreće na lokalnom računalu, i **objavu**, koja je stalno dostupna trkačima na internetu.

3.1 Tijek podataka



Slika 3.1 — Put podataka od fotoaparata do trkačeve galerije.

3.2 Zašto u tri koraka: detekcija, izrez, čitanje

Na testnom skupu od 30 fotografija sa 146 ručno označenih startnih brojeva medijan visine broja iznosi **19 piksela**, a 68 % brojeva je zakrenuto (trkači se nagnju, brojevi se gužvaju). Nijedan OCR alat ne može pouzdano pročitati tako sitan broj iz cijele fotografije, pa cjevovod radi ovako:



Isti kod za izrez i normalizaciju koristi se u mjerenjima i u produkciji — mjerenja zato odgovaraju stvarnom radu.

Slika 3.2 — Faze OCR cjevovoda.

3.3 Kako trkač pronalazi fotografije

- Trkač upiše startni broj; preglednik pozove funkciju `find_runner()` u bazi.
- Baza provjeri da postoji objavljeni događaj i trkač s tim brojem.
- Za svaku fotografiju događaja traži se očitane koje je **identično** broju ili se od njega razlikuje za **najviše jednu znamenku** (Levenshteinova udaljenost 1, uz razumnu duljinu broja).
- Svaka pronađena fotografija dobiva ocjenu `pouzdanost × sličnost` i oznaku `exact` ili `fuzzy`.
- Rezultat se vraća u jednom odgovoru: profil trkača + popis fotografija poredan po kilometru staze i vremenu snimanja.
- Sličice i fotografije učitavaju se izravno iz spremišta slika preko CDN-a.

ZAŠTO TOLERANCIJA JEDNE ZNAMENKE

Prepoznavanje na izrezima daje 78,8 % točno pogođenih brojeva, ali 91,1 % uz toleranciju jedne znamenke — dodatnih 12 postotnih bodova bez ikakve promjene modela. Najčešća pogreška je „odrezana“ prva znamenka (1514 → 14 , 3885 → 88), a ne izmišljeni brojevi, pa je tolerantna pretraga vrlo učinkovita.

4 Komponente sustava

4.1 OCR cjevovod (Python)

Paket `src/marathon_ocr/` je jezgra sustava. Detektori i prepoznavачи su izmjenjivi iza zajedničkog sučelja, pa se svaki dio može zamijeniti boljim bez promjene ostatka.

MODUL	ULOGA
<code>detectors/</code>	YOLOBibDetector — vlastiti, dotrenirani YOLO11 detektor startnih brojeva (glavni). PersonDetector — standardni YOLO za osobe. TorsoHeuristicDetector — rezervna heuristika (područje trupa). WholeImageDetector — kontrolna varijanta za mjerenja.
<code>crops.py</code>	Izravnavanje zakrenutih brojeva, dodavanje ruba i povećanje malih izreza prije čitanja.
<code>recognizers/</code>	EasyOCR (glavni, ograničen na znamenke), PaddleOCR, TrOCR i VLM (Claude) kao alternativni pogoni; CascadeRecognizer spaja brzi lokalni pogon s AI rezervom.
<code>pipeline.py</code>	BibPipeline : fotografija ulazi, izlazi popis svih kandidata s pouzdanošću i okvirom.
<code>dataset.py</code> , <code>metrics.py</code>	Učitavanje CVAT anotacija (uključujući zakrenute okvire) i metrike: točnost, CER, točnost uz toleranciju jedne znamenke, po veličini broja.

Kaskadno prepoznavanje

Pouzdanost koju EasyOCR prijavljuje izvrsno predviđa ispravnost: svako očitavanje s pouzdanošću iznad 0,8 bilo je točno (uz toleranciju jedne znamenke). Zato se samo nesigurna očitavanja (ispod praga 0,4 — oko 10 % izreza) šalju jačem, ali skupljem AI modelu. Na događaju od 20.000 fotografija to je oko 6.000 poziva — trošak od nekoliko dolara po utrci, umjesto ~60 \$ za slanje svega AI modelu.

Pomoćni alati (`scripts/`)

SKRIPTA	NAMJENA
<code>run.py</code>	Obrada jedne fotografije ili cijele mape iz naredbenog retka.
<code>train_bib_detector.py</code>	Dotreniranje YOLO11 detektora na označenom skupu (Roboflow izvoz); <code>resume_bib_training.py</code> nastavlja prekinuto treniranje.
<code>eval_recognizers.py</code> , <code>calibrate.py</code> , <code>eval_end_to_end.py</code>	Mjerenje točnosti prepoznavача, kalibracija praga kaskade i mjerenje cijelog cjevovoda na punim fotografijama.
<code>check_env.py</code>	Provjera GPU okruženja stvarnim izračunom na kartici.
<code>make_demo_gallery.py</code>	Izrada demo galerije s označenim brojevima za prezentacije.
<code>app.py</code>	Testno sučelje: povuci fotografiju u preglednik i vidi koje brojeve sustav pronalazi.

4.2 Aplikacija za pregled (`review_app.py`)

Lokalna Streamlit aplikacija kojom operater provjerava rezultate prije objave:

- odabir mape fotografija (sistemski dijalog ili upis putanje), popis nedavnih mapa;
- prikaz fotografije s označenim okvirima i očitanim brojevima te pouzdanošću;

- brisanje pogrešnih brojeva i dodavanje propuštenih (više brojeva odjednom, odvojenih zarezom);
- traka napretka i mreža za skok na bilo koju fotografiju; napredak se automatski sprema u mapu (`.marathon_ocr_review.json`), pa se rad može prekinuti i nastaviti;
- izvoz `bib_export.csv` (ime fotografije → potvrđeni brojevi).

4.3 Uvozne skripte (`web/scripts/`)

SKRIPTA	ŠTO RADI
<code>import-results.mjs</code>	Unosi trkače i rezultate iz CSV-a mjerača vremena. Automatsko prepoznavanje stupaca (HR/EN), <code>--map</code> za ručno mapiranje, <code>--date-order</code> za američke formate, <code>--dry-run</code> .
<code>import-bibs.mjs</code>	Unosi izvoz aplikacije za pregled. Uz <code>--review</code> unosi i odbačena očitavanja s niskom pouzdanošću, kako bi tolerantna pretraga ipak pronašla fotografije s djelomično nečitljivim brojem.
<code>upload-photos.mjs</code>	Postavlja fotografije u spremište: web verziju (smanjenu, opcionalno s vodenim žigom) u javno, a originale u privatno spremište.
<code>seed-demo.mjs</code>	Unosi demo trkače u pravu bazu radi testiranja.
<code>check-deploy-env.mjs</code>	Sprječava objavu stranice bez povezane baze (da se na javnoj adresi ne bi prikazivali demo podaci).

4.4 Baza podataka (Supabase / PostgreSQL)


TABLICA	SADRŽAJ
<code>events</code>	Događaj (naziv, izdanje, datum, grad, prva godina) i zastavica <code>published</code> .
<code>races</code>	Utrke unutar događaja (maraton, polumaraton, 10 km) s duljinom.
<code>runners</code>	Jedan red po startnom broju: ime, kategorija, klub, nacionalnost, vremena, plasmani, status. Sadrži osobne podatke — nije izravno čitljiva.
<code>photos</code>	Fotografija: putanje u spremištu, dimenzije, vrijeme snimanja, fotograf, točka i kilometar staze.
<code>detections</code>	Svaki kandidat očitavanja: broj, pouzdanost, rang, okvir, visina izreza, izvor (<code>ocr</code> / <code>review</code> / <code>manual</code>). Trigram (GIN) indeks za brzu pretragu.
<code>orders</code>	Zapis preuzimanja/narudžbi po startnom broju.

Funkcije: `find_runner()` — jedini ulaz u podatke o trkaču; `event_stats()` — zbirni brojači za naslovnicu (bez osobnih podataka); `runner_pace()` — tempo izračunat iz vremena, nikad pohranjen.


Spremišta slika: `race-previews` (javno, web veličina) i `race-originals` (privatno, pristup samo putem kratkotrajnog potpisanog linka od 5 minuta).

4.5 Javna web stranica (`web/`)


Next.js 16 / React 19 aplikacija s tri zaslona: naslovnica, pretraga i galerija trkača s preglednikom. Izvozi se kao potpuno statična stranica (bez vlastitog poslužitelja) i posluhuje s Cloudflareove mreže.




Slika 4.1 — Zaslon pretrage: naslovnica s brojačima lijevo, polje za startni broj desno.




Slika 4.2 — Profil trkača: ciljno vrijeme, tempo, plasman i animirana staza.



Slika 4.3 — Galerija: fotografije poredane po točkama na stazi.



Slika 4.4 — Preglednik fotografija s imenom fotografa i preuzimanjem.



Slika 4.5 — Isto iskustvo na mobitelu: pretraga, profil, galerija.

5 Tehnološki stog

Provjerene tehnologije otvorenog koda i upravljane usluge s besplatnim ili jeftinim planovima. Nema vlastitih poslužitelja koje treba održavati.

SLOJ	TEHNOLOGIJA	ULOGA
Obrada / AI	Python 3	Jezik OCR cjevovoda i alata
	PyTorch (CUDA 12.8)	Izvršavanje modela na grafičkoj kartici
	Ultralytics YOLO11	Detekcija startnih brojeva (dotrenirani model) i osoba
	EasyOCR	Čitanje znamenki (glavni prepoznavač)
	Claude (Anthropic API)	Opcionalna AI rezerva za nesigurna očitavanja
	Pillow, NumPy	Obrada slika
Alati za operatera	Streamlit	Aplikacija za pregled i testno sučelje
	Roboflow, CVAT	Označavanje podataka za treniranje i mjerenje
Web stranica	Next.js 16 (statični izvoz)	Okvir aplikacije
	React 19, TypeScript 5	Sučelje i tipizirani kod
	supabase-js	Pristup bazi iz preglednika
	Leaflet	Karta staze
Podaci	Supabase (PostgreSQL)	Baza, sigurnosna pravila (RLS), funkcije
	pg_trgm, fuzzystmatch	Trigram indeks i Levenshteinova udaljenost za tolerantnu pretragu
	Supabase Storage	Spremište web verzija i originala fotografija
Uvoz	Node.js 20+	Uvozne skripte
	csv-parse, sharp	Čitanje CSV-a, smanjivanje i vodeni žig
Isporuka	Cloudflare (Workers static assets / Pages)	Globalna mreža za posluživanje stranice, sigurnosna zaglavlja
Hardver	NVIDIA RTX 5070 (Blackwell)	Lokalna obrada; nema troška GPU-a u oblaku

5.1 Arhitektonske odluke

ODLUKA	RAZLOG
Obrada kao serijski posao, ne kao usluga	Nema redova čekanja, automatskog skaliranja ni „hladnih startova“; jedno računalo obradi cijeli događaj.
Statična web stranica	Nema poslužitelja koji se može srušiti pod opterećenjem; Cloudflare poslužuje datoteke iz stotina lokacija besplatno.
Provjera u bazi, ne u poslužitelju	Sva osjetljiva logika je u PostgreSQL funkciji sa sigurnosnim pravilima, zato stranica može biti statična.
Pohranjuju se svi kandidati očitavanja	Odabir jednog „najboljeg“ broja po izrezu tiho gubi fotografije; tolerantna pretraga treba sve kandidate.
Mjerna jedinica je „trkač je našao fotografiju“	Točnost se mjeri uz toleranciju jedne znamenke jer to odgovara stvarnom iskustvu pretrage.

6 Kapacitet: koliko korisnika sustav podnosi

Kratki odgovor: uz trenutni kod i najmanju plaćenu Supabase instancu, sustav podnosi oko **40.000 pretraga na sat**, što odgovara **oko 1.000–1.500 istovremenih posjetitelja**. Web stranica sama po sebi nema praktičnog ograničenja. Uz jednu optimizaciju upita (opisanu niže) kapacitet raste otprilike šest puta.

∞

statična stranica na Cloudflareu —
zahtjevi za statične datoteke su
besplatni i neograničeni

~11 / s

pretraga u sekundi, izmjereno (≈
40.000 na sat)

~1.000–1.500

istovremenih posjetitelja uz trenutni
upit

6.1 Gdje je usko grlo

Posjet trkača sastoji se od tri vrste prometa. Svaka ima drukčije ograničenje:

PROMET	TKO GA POSLUŽUJE	OGRAIČENJE
Stranica (HTML, JS, CSS)	Cloudflare, statične datoteke	Nema — zahtjevi za statične datoteke su besplatni i neograničeni na svim planovima.
Pretraga (1 upit po broju)	Supabase PostgreSQL, funkcija <code>find_runner()</code>	Glavno ograničenje — procesorsko vrijeme baze. Vidi 6.2.
Fotografije	Supabase Storage + CDN	Mjesečni prijenos podataka (egress). Vidi 6.3.

6.2 Mjerenje pretrage

Funkcija `find_runner()` iz sheme projekta testirana je alatom `pgbench` na PostgreSQL 16 s 2 vCPU jezgre (usporedivo s Supabase instancom *Micro*, koja je uključena u Pro plan) i sintetskim podacima veličine velikog maratona:

- 1 događaj, **10.000 trkača**, **20.000 fotografija**, **100.000 kandidata očitavanja** (5 po fotografiji);
- svaki upit traži nasumičan startni broj, uključujući tolerantno podudaranje.

ISTOVREMENI UPITI	PRETRAGA / S	PROSJEČNO ČEKANJE	NAPOMENA
1	6,4	0,16 s	jedan korisnik
10	12,0	0,84 s	baza je potpuno iskorištena
50	10,8	4,6 s	propusnost ista, raste samo čekanje

Pod preopterećenjem sustav se ne ruši — upiti se stavljaju u red i odgovor dolazi sporije. Supabase na instanci Micro prihvaća do 200 istovremenih veza preko poolera.

Od pretraga u sekundi do istovremenih posjetitelja

Posjetitelj ne pretražuje neprekidno: upiše broj i nekoliko minuta gleda fotografije (koje ne opterećuju bazu). Uz pretpostavku da prosječan posjet traje 3 minute i uključuje 1,5 pretragu:

$$\begin{aligned} \text{istovremeni posjetitelji} &\approx \text{pretraga/s} \times \text{trajanje posjeta (s)} \div \text{pretraga po posjetu} \\ &\approx 11 \times 180 \div 1,5 \approx 1.300 \end{aligned}$$

Scenariji za dan utrke

SCENARIJ	POTREBNO	TRENUTAČNI KAPACITET (~11/S)
10.000 trkača pretražuje tijekom prvog sata nakon objave	~3 / s	Bez problema
10.000 trkača + obitelji (×2) u istom satu	~6 / s	Bez problema
Svih 10.000 trkača u istih 15 minuta (npr. nakon SMS obavijesti)	~11 / s	Na granici — preporuka 6.4

6.3 Prijenos fotografija

Web verzija fotografije (1600 px, JPEG kvalitete 80) ima otprilike 300–400 KB. S 20.000 fotografija i oko tri trkača po fotografiji, prosječan trkač ima desetak fotografija, dakle jedan posjet galerije prenosi približno **4 MB**.

SUPABASE PLAN	UKLJUČENI PRIJENOS / MJ.	≈ POSJETA GALERIJE	IZNAD KVOTE
Free	5 GB + 5 GB (CDN)	~1.200–2.500	nedovoljno za utrku
Pro (25 \$/mj.)	250 GB + 250 GB (CDN)	~60.000–120.000	0,09 \$/GB (≈ 0,35 \$ na 1.000 posjeta)

Alternativa: premještanje javnih web verzija na Cloudflare R2 (bez naknade za prijenos) — u kodu je to promjena samo dviju funkcija u `lib/supabase.ts`.

6.4 Kako povećati kapacitet

MJERA	UČINAK	NAPOMENA
Optimizacija upita <code>find_runner()</code>	~6× (izmjereno 60–72 / s)	Umjesto prolaska kroz sve fotografije događaja, najprije se filtriraju kandidati očitavanja koji odgovaraju broju, a zatim se dohvaćaju samo njihove fotografije. Isti rezultat, izmjereno 17 ms po upitu.
Veća Supabase instanca	~2–4×	Small (15 \$/mj.), Medium (60 \$/mj.) — može se uključiti samo za tjedan utrke.
Predmemoriranje odgovora	velik	Rezultati se nakon objave ne mijenjaju, pa se odgovori mogu keširati na rubu mreže.
Paralelni upload	brža objava	Upload fotografija trenutačno ide jedna po jedna; skup radnika skraćuje objavu 20.000 fotografija.

ZAKLJUČAK

Uz optimizirani upit i Supabase Pro plan sustav realno podnosi **oko 250.000 pretraga na sat i 7.000+ istovremenih posjetitelja**, što pokriva i najveće utrke u regiji. Prije dana utrke preporučuje se test opterećenja na stvarnoj produkcijskoj bazi.

6.5 Brzina obrade fotografija

MJERA	VRIJEDNOST	IZVOR
Prepoznavanje jednog izreza — RTX 5070	10,4 ms	izmjereno
Prepoznavanje jednog izreza — procesor	111 ms	izmjereno
Događaj od 20.000 fotografija (~60.000 izreza)	~10 min	izračun iz mjerenja

Vrijeme detekcije i učitavanja datoteka dolazi na to; cijeli događaj realno se obradi unutar jednog popodneva na jednom računalu, bez troška računala u oblaku.

7 Točnost prepoznavanja

Mjereno na namjerno teškom testnom skupu: 30 smanjenih web fotografija (neke samo 900×600 px) sa 146 ručno označenih brojeva. Originali fotografa (~6000 px širine) daju brojeve visoke 120–150 px, pa su stvarni rezultati bolji.

7.1 Čitanje broja po veličini

VELIČINA BROJA	BROJ UZORAKA	TOČNO	UZ TOLERANCIJU 1 ZNAMENKE
Sitni (< 20 px)	82	76,8 %	89,0 %
Mali (20–40 px)	47	80,9 %	91,5 %
Veliki (≥ 40 px)	17	82,4 %	100,0 %
Ukupno	146	78,8 %	91,1 %

7.2 Kaskada: EasyOCR + AI rezerva

PRAG POUZDANOSTI	PRIHVAĆA EASYOCR	TOČNOST PRIHVAĆENIH (TOL. 1)	ŠALJE SE AI MODELU
0,3	92,5 %	97,0 %	11 / 146
0,4 (zadano)	90,4 %	98,5 %	14 / 146
0,6	82,9 %	99,2 %	25 / 146
0,7	78,1 %	100,0 %	32 / 146

7.3 Što to znači u praksi

- **Kvaliteta izvornih fotografija važnija je od modela.** Svi brojevi viši od 40 px pročitani su ispravno. Fotografi trebaju predati originale, ne smanjene JPEG-ove.
- **Detekcija je ključ.** Prepoznavanje na ispravno izrezanim brojevima je gotovo riješeno; zato projekt koristi vlastiti dotrenirani YOLO11 detektor startnih brojeva umjesto grube heuristike.
- **Lažno pozitivni rezultati su gori od propuštenih.** Tuđa fotografija u galeriji smeta više od jedne propuštene, zato su „vjerojatna“ podudaranja uvijek označena, a operater u aplikaciji za pregled uklanja pogrešna očitavanja.
- **Ljudska provjera zatvara krug.** Kombinacija automatskog prepoznavanja i brzog pregleda daje točnost koju nijedan od ta dva pristupa ne postiže sam.

8 Sigurnost i privatnost

8.1 Zaštita podataka u bazi

- **Row Level Security** uključen je na svim tablicama. Tablice `runners` i `orders` nemaju nijedno pravilo čitanja — javni ključ u pregledniku vidi nula redova.
- Fotografije i očitavanja čitljivi su **samo za objavljene događaje**.
- Jedini ulaz u podatke o trkaču je funkcija `find_runner()` (`SECURITY DEFINER`), koja vraća samo podatke za traženi broj — cijeli popis trkača nije moguće preuzeti.
- Servisni ključ (puna prava) koristi se samo u uvoznim skriptama na računalu operatera i nikad ne ulazi u web stranicu.
- Originali fotografija su u privatnom spremištu; pristup samo putem potpisanog linka koji vrijedi 5 minuta.

8.2 Zaštita web stranice

Cloudflare primjenjuje sigurnosna zaglavlja na svaki odgovor:

ZAGLAVLJE	UČINAK
<code>Content-Security-Policy</code>	Stranica smije učitavati sadržaj samo s vlastite domene i iz Supabasea; zabrana ugradnje u tuđe stranice.
<code>Strict-Transport-Security</code>	Samo HTTPS, dvije godine, uključujući poddomene.
<code>X-Frame-Options: DENY</code> , <code>X-Content-Type-Options</code>	Zaštita od clickjackinga i pogrešnog tumačenja datoteka.
<code>Permissions-Policy</code>	Isključeni lokacija, mikrofonska, kamera i plaćanje u pregledniku.
<code>Referrer-Policy</code> , <code>Cross-Origin-Opener-Policy</code>	Ograničeno curenje informacija prema drugim stranicama.

8.3 GDPR i pravna dokumentacija

U mapi `legal/` pripremljeni su nacrti koje prije objave treba pregledati pravnik i dopuniti podacima organizatora:

DOKUMENT	SADRŽAJ
Politika privatnosti	Voditelj obrade, kategorije podataka, pravne osnove, rokovi čuvanja, prava ispitanika.
Uvjeti korištenja	Pravila korištenja usluge, licenca za preuzete fotografije, autorska prava fotografa.
Politika kolačića	Samo nužna lokalna pohrana (jezik); bez analitike i oglašavanja.
DPIA predložak	Procjena učinka na zaštitu podataka (GDPR čl. 35) s tablicom rizika i mjera.
DSAR i uklanjanje	Postupak za zahtjeve ispitanika i uklanjanje fotografija, rok odgovora od mjesec dana, točan popis podataka za brisanje.
Memorandum o licencama	Licenca Ultralytics YOLO (AGPL-3.0) i prijenos podataka AI rezervi izvan EU-a.

9 Operativni priručnik: jedan događaj

Koraci od praznog računala do objavljene galerije.

9.1 Jednokratna priprema

```
# Python okruženje (Windows). PyTorch mora biti cu128 build za RTX 50xx.
python -m venv .venv && .venv\Scripts\activate
pip install torch torchvision --index-url https://download.pytorch.org/whl/cu128
pip install -r requirements.txt
python scripts/check_env.py          # mora potvrditi sm_120 i uspješan izračun na GPU-u

# Web i uvozne skripte
cd web && npm install
cp .env.example .env.local          # upisati Supabase URL, anon ključ, servisni ključ
```

U Supabase SQL editoru jednom se pokreće `web/supabase/schema.sql` — stvara tablice, indekse, sigurnosna pravila, funkcije i oba spremišta. Skripta se može sigurno pokrenuti više puta.

9.2 Na dan utrke

1 Prikupiti fotografije

Svaki fotograf predaje originale u zasebnu mapu. Točka na stazi može se odrediti prefiksom imena datoteke (`finish_`, `10k_`) ili naknadno parametrom.

2 Pregled i ispravak

`streamlit run review_app.py` → odabrati mapu → proći fotografije, potvrditi ili ispraviti brojeve → *Export CSV*. Napredak se sprema automatski.

3 Uvesti rezultate utrke

```
node scripts/import-results.mjs --csv ../results.csv --dry-run # provjera mapiranja
node scripts/import-results.mjs --csv ../results.csv
```

4 Uvesti očitane brojeve

```
node scripts/import-bibs.mjs --csv "C:/photos/zagreb-2026/bib_export.csv" \
  --review "C:/photos/zagreb-2026/.marathon_ocr_review.json"
```

5 Postaviti fotografije

```
npm i -D sharp
node scripts/upload-photos.mjs --dir "C:/photos/zagreb-2026" --originals --watermark
```

6 Objaviti

U tablici `events` postaviti `published = true`. Od tog trenutka trkači pronalaze svoje fotografije.

9.3 Objava web stranice na Cloudflare

POSTAVKA	VRIJEDNOST
Build command	<code>npm run build</code>
Build output directory	<code>out</code>
Root directory	<code>web</code>
Varijable okruženja	<code>NEXT_PUBLIC_SUPABASE_URL</code> , <code>NEXT_PUBLIC_SUPABASE_ANON_KEY</code> , <code>NEXT_PUBLIC_EVENT_SLUG</code>

Servisni ključ se **ne dodaje** u Cloudflare. Alternativno iz naredbenog retka: `wrangler deploy` (konfiguracija u `wrangler.jsonc`).

9.4 Konfiguracija

VARIJABLA	ZNAČENJE
<code>NEXT_PUBLIC_EVENT_SLUG</code>	Koji događaj stranica prikazuje (npr. <code>zagreb-2026</code>).
<code>NEXT_PUBLIC_EVENT_TZ</code>	Vremenska zona za vrijeme snimanja (<code>Europe/Zagreb</code>).
<code>NEXT_PUBLIC_BRAND_MARK</code> / <code>_ICON</code>	Znak utrke u zaglavlju i ikona stranice.
<code>NEXT_PUBLIC_WATERMARK</code>	Tretiraju li se web verzije kao fotografije s vodenim žigom.
<code>SUPABASE_SERVICE_ROLE_KEY</code>	Samo za uvozne skripte, nikad u web stranici.

10 Troškovi rada

Sustav je dizajniran tako da mjesečni troškovi budu minimalni, a obrada ne ovisi o skupim GPU uslugama u oblaku.

STAVKA	TROŠAK	NAPOMENA
Web stranica (Cloudflare)	0 \$	Statične datoteke su besplatne i neograničene.
Baza i spremište (Supabase Pro)	25 \$ / mj.	Uključuje Micro instancu, 8 GB baze, 100 GB spremišta, 250 GB prijenosa, dnevne sigurnosne kopije.
Dodatni prijenos	0,09 \$ / GB	Samo iznad kvote; $\approx 0,35$ \$ na 1.000 posjeta galerije.
Dodatno spremište	0,0213 \$ / GB	Npr. originali 20.000 fotografija (~150 GB) ≈ 1 \$ / mj. iznad kvote.
Obrada fotografija	0 \$	Lokalno računalo s grafičkom karticom.
AI rezerva (opcionalno)	nekoliko \$ / utrci	~6.000 poziva za događaj od 20.000 fotografija.
Jača baza za tjedan utrke (opc.)	+15 do +60 \$ / mj.	Small ili Medium instanca, obračun po satu.

Cijene prema javnim cjenicima Supabasea i Cloudflarea u rujnu 2026.; podložne promjenama.

11 Ograničenja i plan razvoja

STAVKA	STATUS	OPIS
Optimizacija upita pretrage	sljedeće	Filtriranje kandidata prije spajanja s fotografijama; ~6× veći kapacitet (poglavlje 6.4).
Zaštita od automatiziranih upita	prije objave	Ograničenje broja upita ili Cloudflare Turnstile na obrascu za pretragu.
Online plaćanje originala	plan	Integracija s pružateljem plaćanja (npr. Stripe Checkout) preko postojeće funkcije <code>record_order()</code> .
Dodatna provjera identiteta	opcija	Funkcija u bazi već podržava provjeru datuma rođenja uz startni broj; uključuje se jednim parametrom.
Paralelni upload fotografija	plan	Skup radnika umjesto uploada jednu po jednu.
Stvarna karta staze (GPX)	plan	Trenutačno je karta ilustrativna.
Mjerenje cijelog cjevovoda s YOLO detektorom	u tijeku	Potpuno mjerenje „trkač je našao fotografiju“ na punim fotografijama s dotreniranim detektorom.
Odluka o licenci YOLO	prije komercijalne upotrebe	Vidi memorandum u <code>legal/</code> .

12 Pojmovnik

POJAM	ZNAČENJE
OCR	Optičko prepoznavanje znakova — čitanje teksta (ovdje znamenki) sa slike.
Detektor / YOLO	Model koji na slici pronalazi gdje se nalazi objekt (startni broj). YOLO11 je obitelj takvih modela.
Izrez (crop)	Mali dio fotografije koji sadrži samo startni broj.
Pouzdanost	Broj od 0 do 1 kojim model procjenjuje koliko je siguran u očitavanje.
Kaskada	Brzi model obrađuje sve, a samo nesigurne slučajeve proslijeđuje jačem modelu.
VLM	Vizualno-jezični AI model (ovdje Claude) koji može „pročitati” sliku.
Tolerancija jedne znamenke (fuzzy@1)	Očitavanje se smatra podudarnim ako se od broja razlikuje za najviše jednu znamenku (dodanu, izostavljenu ili zamijenjenu).
Levenshteinova udaljenost	Najmanji broj izmjena znakova potrebnih da se jedan niz pretvori u drugi.
Trigram indeks	Indeks u bazi koji ubrzava pretragu sličnih nizova.
RLS	Row Level Security — pravila u bazi koja određuju tko smije vidjeti koji red.
Statični izvoz	Web stranica kao skup gotovih datoteka, bez poslužitelja koji izvršava kod.
CDN	Mreža poslužitelja diljem svijeta koja isporučuje datoteke s lokacije najbliže korisniku.
Egress	Podaci preneseni iz usluge prema korisnicima (npr. učitane fotografije).